

VantaDB es un motor de memoria embebido y persistente para aplicaciones de IA con prioridad local. Guarda recuerdos como registros (namespace + key + payload) y los recupera con búsqueda híbrida: BM25 lexical + HNSW vectorial combinados con RRF.

RAG significa recuperacion aumentada por generacion:  
primero se recuperan los fragmentos relevantes y despues  
se genera la respuesta citando esos fragmentos.  
Sin citas verificables no hay RAG, solo alucinacion con estilo.

El pipeline local es: extraer texto, dividir en chunks con solapamiento, calcular embeddings sin red y guardar cada chunk con su proveniencia (archivo, pagina, indice).  
El chat recupera el mejor chunk y lo devuelve como cita.